

# 中兴捧月“神算师”算法精英挑战赛

具身智能赛道

## 技 术 报 告

基于光流变形的文本引导多模态世界模型

参赛者：何荣臻

深圳大学

2026年5月

## 摘要

本文针对具身智能场景下机器人交互轨迹数据稀缺的核心问题，提出了一种基于光流变形（Flow Warping）的文本引导多模态世界模型。该模型能够在给定前16帧上下文视频和自然语言指令的条件下，自回归地生成未来50帧的视频序列、对应的26维动作向量序列以及26维关节角度序列，实现端到端的多模态轨迹预测。

核心创新点包括：（1）采用光流变形+残差补偿+遮挡掩码的三重合成机制，在保留输入纹理清晰度的同时有效处理运动遮挡问题；（2）设计U-Net编码器与ConvLSTM时序建模相结合的视频预测架构，并通过FiLM（Feature-wise Linear Modulation）机制将文本条件注入所有模块；（3）构建渐进式训练策略，预测长度从5帧逐步扩展至50帧，配合Scheduled Sampling机制显著提升长序列生成稳定性；（4）以CLIP ViT-B/32作为语义对齐桥梁，实现文本指令与视觉生成的跨模态对齐。

该方案不依赖预训练的大规模视频扩散模型或LoRA微调框架，完全基于PyTorch原生实现，具有部署简单、训练高效、可解释性强等优势。实验表明，模型能够稳定收敛并输出符合格式要求的完整轨迹数据，为具身智能数据增强提供了可行的技术路径。

## 一、问题定义与任务背景

### 1.1 任务描述

本赛题要求参赛者基于提供的具身智能交互轨迹数据集，构建一个多模态生成模型。具体而言：

输入：每条测试轨迹提供一段视频的前16帧、对应的前16步动作和关节数据，以及一条自然语言指令描述期望的机器人行为。

输出：模型需要生成未来50个时间步的数据，包括：（1）续接的视频帧序列；（2）50x26维的动作预测矩阵；（3）50x26维的关节角度预测矩阵。

训练集共250条轨迹（涵盖5种任务类型），测试集共100条轨迹。评估指标关注生成数据的真实性、与文本指令的一致性以及整体质量。

### 1.2 技术挑战

| 挑战     | 描述               | 应对策略                       |
|--------|------------------|----------------------------|
| 长时序预测  | 50帧自回归生成误差累积严重   | 渐进式训练 + Scheduled Sampling |
| 多模态联合  | 视频/动作/关节需同时生成且一致 | 统一世界模型 + 共享文本嵌入            |
| 文本引导弱  | 生成结果需符合自然语言指令    | FiLM调制 + CLIP对齐损失          |
| 计算资源约束 | 需在有限GPU显存下完成训练   | 256分辨率 + 轻量级网络设计           |
| 数据稀缺   | 仅250条训练样本        | 数据增强 + 强正则化                |

## 二、方法详解

### 2.1 整体架构

本文提出的系统由四个核心组件构成，形成完整的端到端生成管线：

| 组件             | 功能说明               | 核心技术                                    |
|----------------|--------------------|-----------------------------------------|
| 文本编码器          | 将自然语言指令转换为稠密向量表示   | CLIP ViT-B/32 / SimpleTextEncoder (BiLS |
| Module A：视频预测器 | 根据上下文帧+文本生成未来视频帧   | U-Net + ConvLSTM + Flow Warping         |
| Module B：动作预测器 | 根据视觉上下文+文本预测动作序列   | CNN + Transformer Enc-Dec               |
| Module C：关节预测器 | 根据上下文关节数据+文本预测关节序列 | BiLSTM + FiLM调制                         |
| 综合损失函数         | 协调三个任务的梯度信号        | MSE + L1 + SSIM + CLIP对齐                |

### 2.2 文本编码器

首选方案：CLIP ViT-B/32

利用OpenAI发布的CLIP模型的文本编码分支，提取512维语义嵌入向量。CLIP在大规模图文配对数据上经过对比学习预训练，具备强大的跨模态语义理解能力。推理阶段CLIP参数冻结，仅用于提取特征，不参与梯度更新。

后备方案：SimpleTextEncoder

考虑到部分环境可能无法下载CLIP权重文件，本文设计了轻量级后备方案——SimpleTextEncoder。其结构为：字符级Embedding（字典大小256，维度64）→ 双向LSTM（隐藏维度128）→ 全局平均池化 → 线性投影至256维。该方案完全无外部依赖，确保系统的鲁棒性。

### 2.3 Module A：光流视频预测器

核心思想：为什么不直接生成像素？

传统的像素级视频生成方法（如VAE解码器直接输出RGB值）面临两大困境：（1）高维像素空间优化困难，容易产生模糊伪影；（2）逐帧误差快速累积导致画面崩溃。受光流估计领域启发，本文采用《变形-补偿》范式：与其从零创造每一帧像素，不如预测相邻帧之间的运动场（Optical Flow），然后通过对前一帧进行空间变形（Warping）来获得基础预测，再辅以残差修正和遮挡掩码融合。这种方式天然保留了图像的纹理细节，同时大幅降低了网络的学习负担。

光流变形公式

单帧预测过程如下：输入为prev\_frame（前一帧）、curr\_frame（当前帧）、text\_embed（文本嵌入）。

步骤1 — U-Net编码：将[prev\_frame; curr\_frame]拼接为6通道张量，经4层下采样提取多尺度空间特征。

步骤2 — FiLM文本注入：在每个U-Net跳跃连接层，用text\_embed计算可学习的gamma和beta系数，对特征图进行仿射变换： $\text{FiLM}(x) = \text{gamma}(\text{text}) * x + \text{beta}(\text{text})$

步骤3 — ConvLSTM时序建模：将编码后的特征传入ConvLSTM单元，维持隐状态以捕获跨帧时序依赖关系。

步骤4 — 三路解码头：从ConvLSTM输出分别预测（a）2通道光流场flow、（b）3通道残差residual、（c）1通道遮挡掩码mask（Sigmoid激活）。

步骤5 — 合成输出： $\text{pred\_frame} = \text{mask} * \text{warp}(\text{curr\_frame}, \text{flow}) + (1 - \text{mask}) * \text{residual}$ 。其中warp操作使用双线性插值采样，padding\_mode设为border以保持边缘连续性。

### 自回归多帧生成

（1）Warm-up阶段：用16帧上下文数据依次通过encode\_and\_predict，建立初始ConvLSTM隐状态。（2）预测阶段：从倒数第二帧和最后一帧出发，每步预测下一帧；将预测结果作为下一步输入，滚动推进至50帧。（3）训练时的Scheduled Sampling：早期（epoch 1~30）以较高概率（最高80%）使用真实帧（Teacher Forcing），逐步降低至0%。

## 2.4 Module B：动作预测器

动作预测器负责生成26维连续动作向量序列，结构如下：

| 层级                  | 结构                        | 输出维度 |
|---------------------|---------------------------|------|
| 视觉编码器               | 4层CNN(3x3卷积) + 最大池化 + GAP | 256  |
| FiLM调制层             | 用text_embed调节视觉特征         | 256  |
| CrossAttention      | 文本Query对视觉Key-Value做交叉注意力 | 256  |
| Transformer Encoder | 4层Self-Attention + FFN    | 512  |
| Transformer Decoder | 2层Cross-Attention(查询文本)   | 512  |
| 线性输出层               | 全连接映射到动作空间                | 26   |

## 2.5 Module C：关节预测器

关节预测器采用简洁的双层BiLSTM架构：输入为上下文关节序列（16x26）+ 文本嵌入；结构为Linear投影 -> BiLSTM(layer1, hidden=512) -> FiLM调制 -> BiLSTM(layer2, hidden=512) -> Linear输出(26维)。FiLM调制的位置在两层LSTM之间，使文本信息在中间表示层面介入时序建模过程。

# 三、训练策略

## 3.1 渐进式预测长度

这是本文最重要的训练策略之一。直接要求模型从epoch 1就预测50帧几乎不可能收敛（梯度信号过于稀疏）。因此设计如下课程：

| Epoch范围 | 预测帧数 | 目的            |
|---------|------|---------------|
| 1 ~ 8   | 5帧   | 快速建立基本的运动感知能力 |
| 9 ~ 15  | 10帧  | 扩展短期预测窗口      |
| 16 ~ 30 | 25帧  | 中期预测能力培养      |
| 31 ~ 80 | 50帧  | 完整的任务目标训练     |

3.2 损失函数设计

总损失 = video\_loss x vw + action\_loss x aw + joint\_loss x 1.0

其中video\_loss由四项组成：

| 损失项       | 权重      | 作用           |
|-----------|---------|--------------|
| MSE       | 1.0     | 像素级重建精度（主损失） |
| L1        | 0.2     | 增强边缘清晰度      |
| SSIM Loss | 0.15    | 结构相似性保持      |
| CLIP对齐    | 0~0.3渐进 | 文本-视频语义一致性   |

动态权重调整：(1) 视频权重 vw: 0.5 -> 2.0 线性增长；(2) 动作权重 aw: 3.0 -> 1.0 线性递减；(3) CLIP对齐权重 cw: epoch<20时为0，之后按min(0.3, (epoch-20)x0.015)渐进启用。

3.3 优化器与调度

| 参数组              | 学习率  | 说明                     |
|------------------|------|------------------------|
| 动作预测器 (Module B) | 5e-5 | Transformer类参数通常用较小LR  |
| 关节预测器 (Module C) | 1e-4 | LSTM中等LR               |
| 视频预测器 (Module A) | 2e-4 | 核心模块，较大LR加速收敛          |
| 文本编码器            | 1e-4 | 后备SimpleTextEncoder的LR |

优化器：AdamW, weight\_decay=1e-5 | 调度器：CosineAnnealingLR, T\_max=80轮 | Batch Size: 1（256x256分辨率下单样本训练以节省显存）

3.4 数据增强

训练时对输入数据进行以下在线增强：(1) 随机水平翻转（概率0.5）：扩充视角多样性；(2) 随机颜色抖动（亮度±10%、对比度±10%）：增强颜色鲁棒性；(3) 随机时间裁剪：从66帧中随机

选取连续16帧作为上下文，增加时序变化。

## 四、消融实验与分析

### 4.1 Checkpoint对比分析

训练过程中保存了不同轮次的模型快照（每20轮一次），以及全程最优模型（best\_model.pt，即验证loss最低的检查点）：

| Checkpoint    | 训练阶段特点           | 预期表现          |
|---------------|------------------|---------------|
| ckpt_e20      | 刚进入25帧预测阶段，仍在适应中 | 短程预测尚可，长程易退化  |
| ckpt_e40      | 已稳定进行25帧预测训练     | 中期预测质量较好      |
| ckpt_e60      | 已切换至50帧预测约30轮    | 接近完整能力，仍有优化空间 |
| ckpt_e80      | 完成全部80轮训练        | 最终模型，理论上最成熟   |
| best_model.pt | 验证集loss最低的快照     | 用于最终提交        |

### 4.2 关键设计选择的合理性分析

#### （1）光流变形 vs 直接像素生成

直接像素生成方法需要网络学习从噪声/隐变量重建整幅图像的所有高频细节，这在仅有250条训练数据的场景下极易过拟合或产生模糊输出。光流变形方法将学习目标分解为《预测运动》和《预测残差》两个相对简单的子任务，有效降低了优化难度。此外，warp操作天然保持了输入帧的纹理连续性，这对机器人场景中的机械臂、工作台等刚性物体尤其重要。

#### （2）渐进式预测的作用

如果不使用渐进式策略而直接训练50帧预测，初期梯度信号极其稀疏（每条样本仅贡献1个有效监督点分布在50个时间步上），导致：收敛速度极慢甚至不收敛；容易陷入《复制最后一帧》的退化解（最小化MSE的最优解就是输出恒定帧）。渐进式策略从根本上解决了这一问题。

#### （3）Scheduled Sampling的价值

纯自回归训练存在exposure bias问题——训练时模型只见过自己的预测作为输入，但错误会逐帧放大。Scheduled Sampling通过混合真实帧和预测帧作为下一步输入，使模型既能学会利用真实信息，又能逐步适应自身预测中的噪声。实验中观察到tf\_ratio从0.8降至0的过程显著减少了推理阶段的漂移现象。

#### （4）FiLM vs CrossAttention文本注入

本文在多个模块中使用了FiLM机制而非更常见的CrossAttention，原因在于：（1）FiLM参数效率高（仅需2xD个额外参数）；（2）计算开销小（无需计算注意力矩阵）；（3）在条件生成任务中被证明与CrossAttention效果相当甚至更好（Perez et al., 2018）。在动作预测器的视觉-文本交互

互层则保留了CrossAttention，因为该处需要更细粒度的特征对齐。

4.3 局限性与改进方向

| 局限                        | 原因分析                | 潜在改进                          |
|---------------------------|---------------------|-------------------------------|
| 长程预测质量衰减                  | 50步自回归误差不可避免地累积     | 引入层次化预测(关键帧+插值)               |
| CLIP语义分数偏低( $\sim 0.24$ ) | CLIP对齐损失启用较晚且权重上限较低 | 提前启用CLIP损失，增大cw上限             |
| 文本条件影响有限                  | FiLM的调制幅度可能不足       | 添加Classifier-Free Guidance后处理 |
| 单一分辨率(256x256)            | 低分辨率丢失细节信息          | 多尺度训练或在推理时超分辨                 |

五、数据生成方法与流程

5.1 推理流程

推理阶段的完整流程如下：

Step 1 — 模型加载：读取best\_model.pt检查点，恢复视频预测器、动作预测器、关节预测器以及可选的文本编码器权重。

Step 2 — 数据预处理：遍历测试集中的100条轨迹，对每条轨迹读取video.mp4并提取前16帧缩放至256x256，解析action.txt/joint.txt获取前16步数据，读取instruction.txt获取文本指令。

Step 3 — 前向推理：将预处理后的数据送入模型，一次性生成50帧预测视频、50步动作预测和50步关节预测。

Step 4 — 后处理与输出：将16帧上下文数据与50帧预测数据拼接组成完整的66帧/66步序列，补充正确的行索引号，写入标准CSV格式的action.txt和joint.txt，将50帧预测帧编码为video.mp4。

5.2 输出格式规范

每条测试轨迹生成一个独立文件夹，包含以下4个文件：

| 文件名             | 格式           | 内容                      |
|-----------------|--------------|-------------------------|
| video.mp4       | MP4视频(H.264) | 66帧(16上下文+50预测)，256x256 |
| action.txt      | CSV文本        | 66行x27列(索引+26维动作)       |
| joint.txt       | CSV文本        | 66行x27列(索引+26维关节)       |
| instruction.txt | UTF-8文本      | 原始指令字符串                 |

5.3 质量校验机制

代码内置了自动质量检查模块，推理结束后执行以下校验：(1) 文件完整性检查：确认100个轨迹文件夹均包含4个必需文件；(2) 维度合规性检查：action.txt和joint.txt均为66行x27列；(3) 数值有效性检查：不含NaN或Inf值；(4) 视频可读性检查：video.mp4能被OpenCV正确解码；(5) CLIP语义一致性评分：抽取10个样本，计算生成视频帧与文本指令的CLIP余弦相似度均值。

## 六、总结与展望

本文针对具身智能轨迹数据稀缺问题，提出了一套完整的基于光流变形的多模态世界模型方案。主要贡献总结如下：

(1) 提出了适用于小规模数据场景的光流变形视频生成范式，避免了传统像素生成方法的模糊和过拟合问题；(2) 设计了渐进式预测长度训练策略和Scheduled Sampling机制，使得50帧长程自回归预测成为可能；(3) 实现了视频、动作、关节三种模态的统一建模与联合生成，通过共享文本嵌入保证跨模态一致性；(4) 提供了完整的端到端训练与推理代码，具有良好的可复现性和工程实用性。

未来改进方向包括：引入扩散模型作为视频生成后端以进一步提升画质、探索层次化关键帧预测以缓解误差累积、以及在更大规模的具身智能数据集上验证方法的泛化能力。



# 附录A：环境配置

## A.1 硬件环境

| 项目  | 配置                       |
|-----|--------------------------|
| GPU | NVIDIA A6000 (96GB VRAM) |
| CPU | AMD EPYC                 |
| RAM | 96GB DDR4                |

## A.2 软件环境

| 组件           | 版本           |
|--------------|--------------|
| Python       | 3.12         |
| PyTorch      | 2.8.0+cu128  |
| CUDA         | 12.8         |
| NumPy        | <2.0 (兼容性考虑) |
| OpenCV       | 4.x          |
| transformers | 4.44.0+      |

## A.3 核心超参数汇总

| 参数             | 值       | 说明                     |
|----------------|---------|------------------------|
| IMG_SIZE       | 256x256 | 输入/输出分辨率               |
| NUM_CONTEXT    | 16      | 上下文帧数                  |
| NUM_PREDICT    | 50      | 预测帧数                   |
| HIDDEN_DIM     | 512     | Transformer/LSTM隐藏维度   |
| TEXT_EMBED_DIM | 512/256 | CLIP/SimpleTextEncoder |
| NUM_EPOCHS     | 80      | 总训练轮次                  |
| BATCH_SIZE     | 1       | 批大小                    |